

ICES AI Platform

État des lieux et directions à prendre

Plateforme d'outils d'analyse et de diagnostic générés par IA. Ce document fait le point sur ce qui est construit aujourd'hui, sur la dette que le projet porte, et propose une séquence de travail priorisée pour les prochains mois.

01 Où en est le projet

Résumé en une page.

La plateforme est **fonctionnelle de bout en bout** : un visiteur parcourt un catalogue, ouvre un outil, remplit un formulaire, obtient un rapport rédigé par un modèle de langage, le télécharge en PDF, et peut passer à un abonnement payant. L'authentification, le quota du plan gratuit, la facturation Stripe et la traduction en sept langues sont branchés.

Le travail des trois dernières semaines a porté sur un point précis : **rendre le moteur crédible**. Le catalogue avait été généré en masse — 1 084 fiches — avec un schéma de sortie unique et des prompts génériques. Les chantiers A, B4-B7 ont remplacé cela par un moteur typé (cinq natures de livrable), un scoring calculé en Python plutôt que demandé au modèle, un routage vers un modèle plus capable pour les outils exigeants, et un socle normatif de **19 référentiels ISO et réglementaires** dont chaque auto-diagnostic est dérivé automatiquement.

1 084

fiches outils dans
data/tools/

19

référentiels normatifs et
autant d'auto-diagnostics
dérivés

64

tests backend, CI bloquante
sur le catalogue

86 %

des fiches ont encore un
prompt resté à l'état de
souche

Le constat central

Le projet a deux catalogues qui cohabitent. D'un côté **19 outils normatifs**, dérivés d'un référentiel, scorés de façon déterministe, routés vers un modèle capable — c'est le produit. De l'autre **1 065 fiches générées** dont 937 portent un prompt souche et 1 064 des champs sans aucune aide au remplissage — c'est du volume d'affichage. La question des prochains mois n'est pas technique : c'est de décider ce qu'on vend, et d'arrêter de compter les 1 084 comme un actif.

Par ailleurs, **l'état de livraison est fragile** : la branche de travail a 14 commits d'avance sur `main`, et 18 fichiers du dernier chantier normatif (9 référentiels, 9 outils) ne sont pas encore versionnés. La CI ne se déclenche que sur `main` et sur les pull requests : rien de ce travail n'a donc été validé automatiquement.

02 Ce qui est construit

Architecture, moteur d'exécution, catalogue.


Deux applications, une frontière nette

Toute la logique métier a été migrée des Route Handlers Next.js vers un backend FastAPI. Le frontend ne parle plus à Supabase que pour l'authentification, et transmet le jeton d'accès à l'API en `Authorization: Bearer`.

Composant	Stack	Responsabilité
<code>src/</code>	Next.js 14 App Router, React 18, Tailwind, shadcn/ui	Rendu, authentification Supabase (email, Google OAuth, cookies, garde dans <code>middleware.ts</code>), i18n des libellés, génération PDF via <code>@react-pdf/renderer</code>
<code>fast_api/</code>	FastAPI, Supabase, Groq, Stripe	Catalogue et fiche outil, traduction à la volée avec cache en base, exécution LLM et quota, facturation Stripe (Checkout + webhook)
<code>data/</code>	JSON versionné	Source de vérité : <code>tools/</code> (1 084 fiches) et <code>referentiels/</code> (19 référentiels)
<code>scripts/</code>	TypeScript + Python	Génération, validation, synchronisation vers Supabase, publication, réécriture des prompts

Le moteur d'exécution

C'est là que le travail récent s'est concentré. La chaîne d'un appel se lit ainsi :



Trois décisions de conception méritent d'être retenues, parce qu'elles conditionnent la suite :

- **Le score est calculé, pas demandé.** Deux exécutions avec les mêmes réponses donnaient auparavant deux scores différents, ce qui disqualifiait un outil censé produire un positionnement. Le modèle ne fait plus qu'interpréter un résultat qu'il ne décide pas.
- **Le routage de modèle n'est pas un confort.** Mesuré sur le même diagnostic ISO 9001, `llama-3.1-8b-instant` rattachait 0 recommandation sur 7 à une clause, contre 8 sur 8 pour `llama-3.3-70b-versatile`. Et avec un référentiel complet en contexte, le modèle par défaut est purement refusé par le fournisseur : au-delà de la qualité, c'est une condition de fonctionnement.
- **La fiche est dérivée du référentiel.** Les quatre premiers auto-diagnostics avaient été saisis à la main, sans garantie que les clauses cotées dans le formulaire soient celles injectées dans le prompt.
`generate_tool_from_referentiel.py` supprime cet écart par construction.

Le catalogue en chiffres

Les 1 084 fiches se répartissent en cinq natures de livrable, introduites au chantier B7 pour remplacer le schéma unique « score / axes / recommandations » qui était imposé à toutes :

Document rédigé		293
Auto-diagnostic		228
Tableau / matrice		86
Profil		73

Les 19 référentiels couvrent ISO 9001, 14001, 45001, 27001, 22000, 22301, 50001, 20000-1, 37001, 37301, 13485, 17020, 17025, 26000, 14040/44, ainsi que le RGPD, le SMI-QSE, l'XP X30-901 et le cadre CES de la Banque mondiale. Chacun donne aujourd'hui exactement un auto-diagnostic.

03 Ce que le projet doit

Dette qualité, dette juridique, dette de livraison.

La dette qualité du catalogue, mesurée

Elle est consignée dans `scripts/quality_baseline.json` et surveillée par un **mécanisme à cliquet** : les fiches déjà atteintes sont signalées en avertissement, mais toute fiche *nouvelle* présentant le défaut fait échouer la CI. La liste ne sait que rétrécir — `--update-baseline` refuse d'ajouter une entrée. Le catalogue ne peut plus se dégrader.

Prompt souche		937 / 1 084
Champs sans aide		1 064 / 1 084
Adossé à un référentiel		19 / 1 084

Un « prompt souche », c'est un prompt qui se borne à rappeler les réponses de l'utilisateur — « *Tu es un consultant expert. L'utilisateur a répondu : ...* ». Il produit un texte plausible et générique. C'est exactement ce qu'un client peut obtenir gratuitement ailleurs, et c'est le cas de **86 % du catalogue**.

Dette juridique — bloquante pour la vente

Chaque référentiel porte une `note_legale` qui dit la même chose : le texte officiel des normes est protégé par le droit d'auteur et n'est jamais reproduit — seules la structure publique et une reformulation des attendus sont utilisées — et la fiche est « **à faire relire par un praticien disposant du texte officiel avant mise en vente** ». Cette relecture n'a pas eu lieu. Tant qu'elle n'est pas faite, les 19 outils qui constituent la vraie valeur du produit ne devraient pas être vendus.

La dette de livraison

- **14 commits** sur `chantier-a-moteur-et-qualite` ne sont pas dans `main`.
- **18 fichiers non versionnés** : 9 nouveaux référentiels (RGPD, ISO 13485, 17020, 17025, 26000, 14040, SMI-QSE, XP X30-901, BM-CES) et leurs 9 auto-diagnostics, plus une renomination de 9 fiches vers la convention `auto-diagnostic-*`.
- La CI se déclenche sur `main` et sur les pull requests. **Rien de ce travail n'a été validé automatiquement.** Le risque n'est pas théorique : la dernière modification de `validate_tools.ts` et de `generate_tool_from_referentiel.py` est elle aussi non commitée.

Les angles morts

Sujet	Situation
Tests frontend	Aucun. Le frontend n'a que <code>tsc --noEmit</code> et le lint. <code>ToolExecutor</code> , la génération PDF et le formulaire dynamique — le cœur de l'expérience — ne sont couverts par rien.
Mesure d'usage	Sentry est optionnel et le seul instrument en place. Aucune analytique produit : on ne sait pas quels outils sont ouverts, exécutés, ni où les utilisateurs abandonnent.
Cycle de vie des fiches	Le couple <code>draft / published</code> existe et <code>publish_tool.ts</code> permet de basculer une fiche relue. Mais aucune politique éditoriale n'est écrite : rien ne dit ce qui justifie une publication.
Traduction	7 langues, mais le catalogue ne sert que les traductions déjà en cache — traduire 1 000 fiches à la volée serait prohibitif. Hors français, l'expérience de navigation reste donc partielle.
Dépendance fournisseur	Le palier gratuit Groq a déjà été atteint sur les outils normatifs. Le dernier commit ne détaille plus que les clauses en écart pour tenir dans la fenêtre — un contournement, pas une solution.

04 Directions à prendre

Sept chantiers, classés par ce qu'ils débloquent.

P0 Sécuriser la livraison avant toute nouvelle fonctionnalité

1 à 2 jours

Versionner les 18 fichiers en attente, ouvrir une pull request depuis `chantier-a-moteur-et-qualite`, faire tourner la CI, fusionner dans `main`. Puis lancer `validate_tools.ts` et `sync_tools_to_db.ts --write` pour que la base reflète le dépôt.

Pourquoi d'abord : trois semaines de travail — le moteur typé, le scoring déterministe, le socle normatif — ne sont ni sauvegardés en amont ni vérifiés. Tout le reste de cette feuille de route s'appuie dessus.

P0 Faire relire les référentiels par un praticien

2 à 4 semaines, externe

Missionner un consultant qualité disposant des textes officiels pour valider les 19 référentiels : justesse des reformulations, absence de reproduction protégée, et surtout absence de promesse de certification là où la norme n'en donne pas (ISO 26000 est explicitement des lignes directrices). Consigner la relecture dans le fichier, référentiel par référentiel.

Pourquoi d'abord : c'est le seul point du projet qui bloque juridiquement la mise en vente, et il ne dépend pas de vous — le délai court dès qu'on le lance. À déclencher en parallèle du reste, pas après.

P1 Trancher la taille du catalogue vendu

1 semaine de décision

Ne publier que les fiches qui passent un seuil éditorial : prompt spécifique, champs aidés, et de préférence un rattachement normatif. Les autres restent en `draft` — présentes dans le dépôt, absentes du catalogue servi. Écrire cette règle dans le README au même titre que la règle de validation des variables de prompt.

Concrètement, cela ferait passer le catalogue public de 1 084 fiches à quelques dizaines. C'est un choix inconfortable, et c'est probablement le plus rentable du document.

Le raisonnement : 1 084 outils dont 86 % rendent un texte générique, c'est un produit qui se disqualifie au premier essai d'un client sérieux. 40 outils dont chacun tient la promesse, c'est une offre. Le mécanisme technique existe déjà — `publish_tool.ts` et le statut `draft` — il ne manque que la décision.

P1 Augmenter le rendement de chaque référentiel

2 à 3 semaines

Un référentiel ne produit aujourd'hui qu'un auto-diagnostic. La même structure de clauses peut en alimenter plusieurs : un **plan d'actions** priorisé par écart, une **checklist d'audit interne**, un **support de revue de direction**, une **matrice de conformité** exportable. Étendre `generate_tool_from_referentiel.py` pour produire ces variantes à partir du même fichier source.

Le raisonnement : écrire un référentiel coûte cher (structure, reformulation, cotation, relecture juridique). En tirer quatre livrables au lieu d'un divise ce coût par quatre, et la cohérence entre les livrables est garantie par construction — c'est exactement l'argument qui a justifié de dériver la fiche du référentiel plutôt que de la saisir.

P1 Instrumenter l'usage

3 à 5 jours

Enregistrer, à chaque exécution : l'outil, la langue, le modèle retenu, la durée, le coût en tokens, et l'issue (succès, échec de validation de sortie, quota, limite fournisseur). Une table Supabase suffit. Exposer un tableau de bord minimal.

Pourquoi : le chantier précédent demande de choisir quels outils garder et lesquels étendre. Sans mesure, ce choix se fera à l'intuition. Et le quota gratuit est passé de 3 à 50 exécutions sans qu'on sache ce que 50 exécutions coûtent réellement.

P2 Sortir de la dépendance au palier gratuit Groq

1 semaine

Passer sur un palier payant ou introduire un second fournisseur derrière `model_router`, qui est déjà le bon point d'insertion. Ajouter une reprise sur échec quand le fournisseur refuse la requête, plutôt que de rogner le contexte.

Pourquoi : les outils normatifs — ceux qui portent la valeur — sont précisément ceux qui saturent la limite. La restriction du prompt aux seules clauses en écart est un bon réflexe de performance, mais elle a été décidée sous contrainte de quota, pas pour la qualité du rapport.

P2 Couvrir le frontend et pré-traduire le catalogue réduit

2 semaines

Des tests sur le parcours d'exécution (formulaire dynamique, rendu par nature de sortie, export PDF), et une pré-traduction en base des fiches publiées — faisable une fois le catalogue ramené à quelques dizaines d'outils, alors que c'était prohibitif à 1 084.

Pourquoi ensuite : ces deux chantiers deviennent nettement moins coûteux après la décision sur la taille du catalogue. Les faire avant, c'est payer pour du volume qu'on s'apprête à retirer.

05 Séquence proposée

Trois mois, en supposant une personne à temps plein sur le sujet.

SEMAINE 1

Remettre le dépôt d'aplomb

Commit, pull request, CI verte, fusion dans `main`, synchronisation de la base. En parallèle, lancer la mission de relecture juridique — le délai externe court dès ce moment.

SEMAINES 2 À 4

Décider ce qu'on vend

Définir le seuil éditorial, appliquer le statut `draft` à tout ce qui ne le passe pas, écrire la règle dans le README. Poser l'instrumentation d'usage en même temps, pour que le mois suivant s'appuie sur des chiffres.

MOIS 2

Faire rendre plus à chaque référentiel

Étendre le générateur aux variantes de livrable — plan d'actions, checklist d'audit, revue de direction. Intégrer les retours de la relecture juridique au fur et à mesure qu'ils arrivent.

MOIS 3

Consolider avant d'ouvrir

Fournisseur LLM payant et reprise sur échec, tests du parcours frontend, pré-translation du catalogue publié. À l'issue : une offre restreinte, relue, mesurée et vendable.

Le fil conducteur

Les trois dernières semaines ont prouvé que le moteur peut produire un livrable sérieux, à condition d'être adossé à un référentiel et routé vers un modèle capable. Les trois prochains mois consistent à **appliquer cette exigence au périmètre entier de ce qu'on vend**, quitte à réduire fortement ce périmètre. Le risque du projet n'est plus technique : il est de continuer à présenter 1 084 outils dont on sait que 86 % ne tiennent pas la promesse.

Document établi le 7 août 2026 à partir de l'état du dépôt `ices_ai_platform`, branche `chantier-a-moteur-et-qualite`, commit `b7e92e6`. Les chiffres du catalogue, de la dette qualité et de la couverture de tests sont mesurés directement sur les fichiers du dépôt ; les estimations de charge et la séquence proposée sont des recommandations.